**Сравнительный анализ стратегий моделирования сезонности в задачах прогнозирования временных рядов с использованием CatBoost**

## 1. Постановка задачи / гипотеза

Прогнозирование временных рядов с выраженной сезонностью остается одной из наиболее сложных и востребованных задач для компаний работающих во многих сферах, таких как ритейл, промышленность и т.д. В то время как классические статистические методы, такие как модели экспоненциального сглаживания (ETS) или сезонная интегрированная модель авторегрессии — скользящего среднего (SARIMA), имеют встроенные механизмы обработки сезонности через параметризацию периодических компонентов, современные алгоритмы на базе градиентного бустинга над решающими деревьями (GBDT), такие как CatBoost, не обладают таким встроенным механизмом. Для таких моделей временная зависимость должна быть явно сконструирована через инжиниринг фичей.

Центральный вопрос данного исследования заключается в определении наиболее эффективного способа репрезентации сезонных паттернов в рамках локальных моделей градиентного бустинга. Основная гипотеза предполагает, что использование гармонических признаков Фурье в сочетании с категориальными календарными переменными обеспечит превосходство над стандартными авторегрессионными лагами за счет более точной аппроксимации гладких сезонных циклов и учета дискретных временных интервалов (взяла гипотезу из источника - https://medium.com/data-science/modeling-variable-seasonal-features-with-the-fourier-transform-18c792102047).

В рамках проверки данной гипотезы были сформулированы следующие задачи:

1. Выявление набора временных рядов с явной, статистически значимой сезонностью, подтвержденной через функцию автокорреляции (ACF).
2. Фиксация набора базовых статистических моделей и выбор единой архитектуры машинного обучения (CatBoost) для проведения экспериментов.
3. Сравнительный анализ шести различных конфигураций признаков, включая только стандартные лаги, сезонные лаги, категориальные признаки календаря, признаки Фурье и их комбинации.
4. Оценка влияния силы сезонности (seasonal strength) и горизонта прогнозирования на относительную эффективность выбранных методов моделирования.

Особое внимание уделяется специфике данных, где сезонные различия могут быть радикальными, что требует от моделей высокой обобщающей способности при сохранении чувствительности к локальным пикам и спадам. Гипотеза также предполагает наличие положительной корреляции между силой сезонности и

увеличением качества прогнозов от использования продвинутых методов инжинирингa фич.

**2. Распределение ролей**

Проект выполняла самостоятельно.

**3. Описание данных**

Мой проект базируется на датасете M4 Monthly — признанном отраслевом стандарте для оценки качества прогнозов. Датасет M4 включает в себя 100 000 временных рядов различной частотности, собранных из таких областей, как микро- и макроэкономика, финансы, демография и промышленность. Для целей данного отчета был выбран сегмент ежемесячных данных (M4 Monthly), содержащий 48 000 временных рядов, что обеспечивает достаточную глубину для анализа годовой сезонности.

Для обеспечения статистической достоверности и чистоты эксперимента был проведен многоэтапный процесс фильтрации данных. На первом этапе из общего массива было просэмплировано 500 рядов для начального анализа. Основным критерием включения ряда в итоговую выборку стало наличие явной сезонности, определяемой через значения функции автокорреляции (ACF) на лаге 12. Пороговое значение $|ACF(12)| \geq 0.3$ было установлено как индикатор очевидной сезонности. В результате фильтрации был сформирован рабочий набор из 438 временных рядов, обладающих выраженной сезонностью. Минимальная длина ряда была ограничена 36 наблюдениями, что позволяет выделить как минимум два полных сезонных цикла для обучения и один цикл для валидации и тестирования. Ряды меньшей длины исключались, так как они не позволяют корректно инициализировать сезонные лаги и признаки Фурье высокой частоты.

**Статистические характеристики набора данных**

| **Параметр** | **Значение** |
|---|---|
| **Общее количество рядов в M4 Monthly** | 48 000 |
| **Количество рядов в эксперименте (после** | 438 |

| | |
|---|---|
| **фильтрации)** | |
| **Частотность данных** | Ежемесячная |
| **Критерий сезонности (ACF лаг 12)** | $\geq$ 8 |
| **Минимальная длина ряда** | 36 месяцев |
| **Основной горизонт прогнозирования** | 18 месяцев |
| **Дополнительные горизонты прогнозирования** | 3 и 6 месяцев |

Данные характеризуются высокой гетерогенностью: присутствуют как стационарные ряды, так и ряды с выраженным трендом и изменяющейся дисперсией. Это создает дополнительные сложности для моделей, требуя эффективного разделения трендовой и сезонной составляющих. Сила сезонности варьируется в широком диапазоне, что позволяет разделить выборку на категории «слабой» (0.3–0.5) и «сильной» (0.5–1.0) сезонности для последующего анализа зависимостей.

Можно явно увидеть распределение силы сезонности  по гистограмме acf_distribution: большинство рядов имеют сильную годовую сезонность (|ACF| 0,7–0,95), порог 0,3 отмечен красной линией.

## 4. Методология эксперимента

Эксперименты проводились **п**оследовательно для трёх горизонтов:

- short (h=3)
- medium (h=6)
- long (h=18)

Для каждого горизонта отдельно запускались бейзлайны и все шесть вариантов глобальных моделей CatBoost.
Основные результаты представлены для горизонта long (h=18). Эксперимент на medium (h=6) не произвёл никакого значимого эффекта и полностью подтвердил выводы,

полученные на short и long горизонтах.
**Модели** для проведения экспериментов:

- Классические (локальные): **AutoTheta**, **AutoETS**.
- Наивные бейзлайны: **Naive**, **SeasonalNaive**.
- Глобальные модели на CatBoost (обучение на всех 438 рядах одновременно):
- lags_only
- lags_seasonal
- lags_calendar
- lags_fourier
- lags_fourier_calendar
- lags_seasonal_calendar

**Валидация**: rolling-window backtesting.
**Дополнительный анализ**: разбиение рядов на weak/strong сезонность + корреляция силы сезонности с улучшением MASE.

### 5. Процесс подготовки признаков

Для каждого ряда формировался обучающий набор данных по принципу скользящего окна. В качестве целевой переменной выступало значение в момент времени t, а в качестве признаков — различные комбинации лагов и производных функций.

Эксперимент включал следующие шесть вариантов признаков:

1. **Lags only (Базовый):** Прямые авторегрессионные лаги с 1 по 13. Этот набор отражает краткосрочную память модели.
2. **Lags + Seasonal Lags:** Базовые лаги дополняются значениями за аналогичные периоды прошлых лет (лаги 12 и 24 для ежемесячных данных).
3. **Lags + Calendar:** Базовые лаги дополняются категориальными признаками (номер месяца и квартал), которые передаются в CatBoost как категориальные фичи.
4. **Lags + Fourier:** Базовые лаги дополняются гармониками Фурье (пары синусов и косинусов с периодом 12), где k = 2 определяет количество гармонических пар.
5. **Lags + Seasonal + Calendar:** Комбинация сезонных лагов и категориальных календарных признаков.
6. **Lags + Fourier + Calendar:** Комбинация гармоник Фурье и категориальных календарных признаков.

### 6. Оценка качества и горизонт прогноза

Прогнозирование осуществлялось рекурсивным методом: модель предсказывает значение на один шаг вперед, которое затем используется в качестве входного признака для следующего шага. Это позволяет оценивать накопление ошибки на длинных горизонтах. Основным горизонтом (horizon) был выбран период в 18 месяцев,

соответствующий стандарту M4 для ежемесячных данных. Дополнительно проводился анализ на коротком горизонте (3 месяца) и среднем (6 месяцев).

Для оценки точности использовались две метрики:

- **sMAPE (Symmetric Mean Absolute Percentage Error):** Симметричная средняя абсолютная процентная ошибка, устойчивая к масштабу данных.
- **MASE (Mean Absolute Scaled Error):** Масштабированная средняя абсолютная ошибка, где знаменателем является ошибка наивного сезонного прогноза. Значение MASE < 1 указывает на то, что модель работает лучше, чем сезонная наивная модель.
- **RMSSE (Root Mean Square Scaled Error)**: это масштабированная метрика ошибки для оценки качества прогнозов временных рядов. Если значение меньше 1, то модель лучше наивного прогноза (random walk). Значение = 1, значит модель на уровне наивного прогноза. Значение больше 1 означает, что модель хуже наивного прогноза

## 7. Статистический контроль

Для сопоставления результатов машинного обучения с классическими подходами были задействованы четыре базовых модели из библиотеки StatsForecast: Naive, Seasonal Naive, AutoETS и AutoTheta. Модель Seasonal Naive является критически важным бейзлайном, так как она напрямую эксплуатирует сезонную структуру без обучения.

## 8. Описание выбранных моделей

### Архитектура CatBoost

CatBoost был выбран в качестве основной модели благодаря его способности эффективно обрабатывать категориальные данные и устойчивости к переобучению на малых выборках.Алгоритм, который строит лес из деревьев решений, где каждое следующее дерево исправляет ошибки предыдущих.CatBoost строит  симметричные деревья, это защищает модель от переобучения (она не может слишком сильно подстроиться под мелкие детали) и позволяет компьютеру делать предсказания невероятно быстро. Кроме того, алгоритм перемешивает данные, чтобы модель не узнала ответ заранее, он использует случайные перестановки данных. Модель обучается на одном подмножестве, а проверяет себя на другом, которое она еще не видела.

Параметры обучения были зафиксированы для всех экспериментов:

- Количество итераций: 600.

- Скорость обучения (learning_rate): 0.03
- Глубина дерева: 4
- L2-регуляризации (l2_leaf_reg): 5.0
- Функция потерь: MAE (Mean Absolute Error) для минимизации влияния выбросов.

**9. Математическое представление сезонных признаков**

В проекте используется тригонометрическое преобразование временных меток в признаки Фурье для моделирования периодических циклов (например, годовых или недельных).
Календарные признаки, такие как месяцы и кварталы выделяются как отдельные категории.

В моделях градиентного бустинга (CatBoost) это позволяет выявлять резкие, специфические отклонения, характерные для конкретных периодов (например, всплески в декабре или спады в январе). Модель рассчитывает статистики для каждого состояния календаря отдельно.

**10. Сезонные лаги**

Использование лагов с периодом в один год дает модели информацию о реальном поведении ряда в прошлом.

Отличие от Фурье в том что время как признаки Фурье описывают идеальную математическую форму волны, сезонные лаги передают фактическую амплитуду сигнала. Это позволяет модели адаптироваться к изменению масштаба. Если общая форма сезона (пики и спады) сохраняется, но уровень ряда вырос по сравнению с прошлым годом, лаги помогут точнее скорректировать прогноз, опираясь на реальный исторический опыт.

## 11. Основные результаты

Сводная таблица (сортировка по mean MASE, горизонт long h=18):

| Модель \ Метрика | MASE mean | MASE median | RMSSE mean | RMSSE median | sMAPE mean | sMAPE median |
|---|---|---|---|---|---|---|
| **AutoTheta** | 0.9244 | 0.7471 | 0.8245 | 0.6913 | 11.0521 | 5.5212 |
| **AutoETS** | 0.9324 | 0.7467 | 0.8235 | 0.6779 | 11.8718 | 5.7060 |
| **Naive** | 1.1479 | 0.8782 | 1.0331 | 0.8182 | 12.7741 | 7.0503 |
| **CatBoost_lags_seasonal_calendar** | 1.1767 | 0.9190 | 1.0515 | 0.8541 | 12.1442 | 7.6496 |
| **CatBoost_lags_fourier_calendar** | 1.1793 | 0.9340 | 1.0530 | 0.8422 | 12.0844 | 7.8094 |
| **CatBoost_lags_calendar** | 1.1841 | 0.9350 | 1.0580 | 0.8444 | 12.0476 | 7.9248 |
| **CatBoost_lags_seasonal** | 1.2030 | 0.9940 | 1.0725 | 0.8892 | 12.1658 | 7.5625 |
| **CatBoost_lags_only** | 1.2074 | 0.9654 | 1.0737 | 0.8672 | 12.1031 | 7.6201 |
| **CatBoost_lags_fourier** | 1.2181 | 0.9331 | 1.0850 | 0.8705 | 12.0517 | 7.7244 |
| **SeasonalNaive** | 1.2558 | 1.0258 | 1.0946 | 0.9422 | 14.2538 | 8.1568 |

Ключевые наблюдения по графикам:

- Боксплоты all_models_comparison и smape_comparison: AutoTheta и AutoETS имеют самое низкое и наиболее компактное распределение ошибок. Все CatBoost-модели и наивные бейзлайны заметно выше.
- Scatter-plotы strength_vs_improvement и improvement_by_strength: слабая положительная связь между силой сезонности и выгодой от сезонных фич (Pearson r = 0.227, p = 0.0000). Красная линия тренда показывает лёгкий положительный наклон.
- График устойчивости horizon_analysis_lineplot: все CatBoost-модели деградируют примерно параллельно при увеличении горизонта; лучший вариант среди них — lags_seasonal_calendar.

Анализ CatBoost по силе сезонности
Результаты разбиения рядов на группы weak (ACF 0.3–0.5) и strong (ACF > 0.5):

| Модель | MASE | RMSSE | sMAPE | Группа |
|---|---|---|---|---|
| **CatBoost_lags_calendar** | 0.8072 | 0.7469 | 22.3837 | weak |
| **CatBoost_lags_seasonal** | 0.8363 | 0.7716 | 22.7598 | weak |
| **CatBoost_lags_fourier_calendar** | 0.8393 | 0.7683 | 22.4966 | weak |
| **CatBoost_lags_only** | 0.8589 | 0.7819 | 22.3715 | weak |
| **CatBoost_lags_seasonal_calendar** | 0.8891 | 0.8109 | 22.8499 | weak |

| | | | | |
|---|---|---|---|---|
| **CatBoost_lags_fourier** | 0.9118 | 0.8230 | 22.1985 | weak |
| **CatBoost_lags_seasonal_calendar** | 1.2351 | 1.1004 | 9.9677 | strong |
| **CatBoost_lags_fourier_calendar** | 1.2485 | 1.1108 | 9.9677 | strong |
| **CatBoost_lags_calendar** | 1.2607 | 1.1213 | 9.9463 | strong |
| **CatBoost_lags_only** | 1.2782 | 1.1331 | 10.0156 | strong |
| **CatBoost_lags_seasonal** | 1.2775 | 1.1336 | 10.0121 | strong |
| **CatBoost_lags_fourier** | 1.2804 | 1.1383 | 9.9889 | strong |

На слабосезонных рядах (weak) все модели показывают MASE < 1. Лучший результат — CatBoost_lags_calendar (MASE = 0.8072, RMSSE = 0.7469). На сильносезонных рядах (strong) все варианты CatBoost имеют MASE > 1. Лучший результат — CatBoost_lags_seasonal_calendar (MASE = 1.2351, RMSSE = 1.1004).

**Анализ результатов экспериментов:**

В рамках проекта на датасете M4 Monthly (438 рядов с видимой сезонностью из 500) на горизонтах short (h=3), medium (h=6) и long (h=18) установлено:

- Классические модели уверенно победили на всех трёх горизонтах (short, medium, long).
- Среди CatBoost лучший результат показал самый сложный вариант (lags_seasonal_calendar). Однако все глобальные модели уступают даже простому Naive.
- Появилась слабая, но статистически значимая положительная корреляция между силой сезонности и улучшением MASE от сезонных признаков: Pearson r = 0.227 (p = 0.0000). На сильно сезонных рядах (strong) сезонные фичи дают небольшой положительный эффект, однако общий уровень ошибок CatBoost остаётся высоким (MASE = 1,23-1,28 на strong-группе).
- Глобальный подход в текущей реализации уступает даже простому Naive и SeasonalNaive.
- Классические модели AutoTheta и AutoETS значительно превосходят все глобальные модели CatBoost (преимущество 27% по MASE_mean на h=18).

Эксперимент на medium (h=6) и short (h=3) горизонте не произвёл никакого значимого эффекта и полностью подтвердил те же закономерности.

- Добавление сезонных признаков (Фурье, календарь, сезонные лаги) дало небольшой эффект только на сильно сезонных рядах, однако общий результат глобальных моделей остаётся неудовлетворительным — они проигрывают даже простому Naive.

Основная причина — недостаточная способность сезонных фич эффективно передавать годовую сезонность в глобальной постановке на полученных данных.

**Влияние силы сезонности (Weak vs Strong)**

Для оценки эффективности предложенных методов был проведен анализ рядов с разной степенью выраженности сезонного сигнала. В качестве метрики силы сезонности использовалась функция автокорреляции (ACF).

1. Ряды с сильной сезонностью (ACF > 0.5) В данных с четко выраженным ритмом внедрение сезонных признаков дает максимальный результат.

В данных с чётко выраженным ритмом внедрение сезонных признаков даёт максимальный эффект по сравнению с базовой моделью lags_only. Лучший результат — CatBoost_lags_seasonal_calendar (MASE = 1,2351), что на 3,4% лучше CatBoost_lags_only (MASE = 1,2782). Тем не менее все CatBoost-варианты остаются выше уровня наивного прогноза (MASE > 1).

2. Ряды со слабой сезонностью (ACF < 0.5) При слабом сигнале все варианты CatBoost показывают MASE < 1, превосходя наивный прогноз. Лучший результат — CatBoost_lags_calendar (MASE = 0,8072, RMSSE = 0,7469).

Здесь есть риск переобучения, так как в условиях слабого сигнала дополнительные математические признаки могут восприниматься моделью как шум. Это заставляет алгоритм искать закономерности там, где их нет, что ведет к переобучению.

Для таких рядов более эффективным оказывается использование упрощенных моделей или усиленная регуляризация признаков Фурье.

Эффект от внедрения сезонных признаков прямо пропорционален силе сезонного сигнала. Моделирование через функции Фурье является наиболее предпочтительным для рядов с высоким показателем автокорреляции, обеспечивая устойчивость прогноза к локальным искажениям.

**Влияние горизонта прогнозирования**

В ходе исследования была выявлена четкая зависимость эффективности признаков от глубины прогноза (горизонта).

1. Короткий горизонт (до 3 месяцев) На краткосрочном этапе наиболее точные результаты показывают модели, опирающиеся на лаги (авторегрессионные зависимости). Здесь временные ряды обладают инерцией. Ближайшее прошлое максимально точно описывает ближайшее будущее, позволяя лагам учитывать текущие временные колебания.

2. Длинный горизонт (от 18 месяцев) При долгосрочном прогнозировании

преимущество переходит к сезонным признакам (Фурье и календарь). При рекурсивном прогнозе (когда модель использует свои же предсказания как входные данные) ошибка накапливается лавинообразно, и лаги быстро теряют актуальность.

Поэтому мы можем воспользоваться преимуществами Фурье и календаря, так как эти признаки являются детерминированными функциями времени. Они выступают в роли якорей, которые не дают прогнозу развалиться и удерживают его в рамках естественной сезонной траектории, независимо от того, насколько далеко мы заходим в будущее. Среди всех CatBoost-вариантов наибольшую устойчивость к росту горизонта демонстрирует CatBoost_lags_seasonal_calendar.

3. Математическое подтверждение (Корреляция Пирсона) Анализ корреляции Пирсона между силой сезонности (ACF) и улучшением метрики MASE подтвердил положительную связь ($r = 0.227$ ($p = 0.0000$)). Чем четче выражен исторический цикл в данных, тем выше математически обоснованная отдача от затрат времени и сил в проектирование сложных сезонных признаков.

Итоговый вывод: Для краткосрочного планирования критически важны лаги, в то время как для стратегического долгосрочного прогноза основой стабильности являются признаки Фурье и календарные компоненты.

**ИТОГИ:**

Проведенное исследование позволяет сделать ряд аргументированных выводов о методах моделирования сезонности в современных GBDT-архитектурах.

**Во-первых,** гипотеза о превосходстве комбинации Фурье + календарь подтверждена частично. Лучшим оказался CatBoost_lags_seasonal_calendar, а не CatBoost_lags_fourier_calendar. Обе комбинированные модели с Calendar превосходят чистые варианты lags_only и lags_fourier.

**Во-вторых,** эффективность сезонных признаков напрямую коррелирует с силой сезонности по ACF. Для рядов со слабой периодичностью сложные признаки не дают значимого преимущества. Лучше использовать адаптивный подход: применять сезонный инжиниринг только после прохождения порога статистической значимости сезонного сигнала.

**В-третьих,** выявлена критическая зависимость от горизонта прогнозирования. Сезонные признаки — необходимое условие для сохранения адекватности прогноза на горизонтах > 1 сезонного периода. В рекурсивных схемах они выполняют роль регуляризаторов, предотвращая дрейф прогноза.

Можно предположить следующие шаги:

- При работе с ежемесячными данными включать минимум две пары гармоник Фурье (k >= 2) в сочетании с сезонными лагами и категориальными признаками.
- CatBoost эффективно обрабатывает категориальные признаки без ручного кодирования, однако их следует сочетать с количественными сезонными индикаторами для максимальной точности.
- Для рядов с высокой зашумлённостью признаки Фурье предпочтительнее сезонных лагов — они менее чувствительны к единичным аномалиям.
- Перед применением сложного инжиниринга фич выполнять диагностику силы сезонности через ACF.

Результаты могут быть масштабированы и на другие частотности (ежедневные, недельные), где сложность сезонных паттернов возрастает. Дальнейшее развитие темы — переход к полноценным глобальным моделям (Global Forecasting Models), потенциально извлекающим общие сезонные закономерности из различных рядов одного домена.